

# Bank Marketing Lead Scoring

EXECUTIVE SUMMARY

Predicción de Suscripción a Depósito a Término

Aprendizaje de Máquina Aplicado · EAFIT · Mayo 2026

Alejandro Osorno · Danna Mendoza

0.816

ROC-AUC EN TEST

70.5%

SUSCRIPTORES CAPTURADOS

24.3%

CLIENTES A CONTACTAR

36.6%

AHORRO VS. CONTACTO TOTAL

## EL PROBLEMA

Un banco portugués realiza campañas de telemarketing para ofrecer depósitos a término. Contactar a toda la base de clientes es costoso: **solo el 11.3% suscribe**. El proyecto construye un sistema de scoring que prioriza a quién llamar primero, reduciendo el esfuerzo a una fracción de la base sin perder la mayoría de conversiones.

## LOS DATOS

**Fuente:** UCI Bank Marketing — 41,188 registros históricos de campañas reales (2008–2010). Variables de perfil del cliente, datos de la campaña y contexto macroeconómico.

## HALLAZGO CLAVE

La variable más influyente no es el perfil del cliente sino el **nivel de empleo (nr.employed)**, un indicador macroeconómico. El modelo predice más *cuándo* es buen momento para la campaña que *a quién* llamar. Las condiciones económicas favorables deben ser el primer criterio de lanzamiento.

| Variable         | Importancia |
|------------------|-------------|
| nr.employed      | 0.134       |
| nunca_contactado | 0.036       |
| euribor3m        | 0.029       |
| contact          | 0.022       |

Top 4 predictores (permutation importance, test).

## METODOLOGÍA

Se compararon **seis configuraciones de modelos** de cuatro familias distintas bajo validación cruzada estricta de cinco folds. La variable duration (duración de la llamada) se excluyó desde el inicio por fuga de información: no se conoce antes de llamar.

| Modelo              | AP (CV)      |
|---------------------|--------------|
| Regresión Logística | 0.445        |
| Árbol (GridSearch)  | 0.432        |
| Random Forest       | 0.458        |
| SVM RBF             | 0.351        |
| RF (Optuna)         | 0.459        |
| <b>LightGBM ★</b>   | <b>0.463</b> |

AP en validación cruzada 5-fold. LightGBM seleccionado como modelo final.

## UMBRAL DE DECISIÓN

El umbral por defecto (0.5) es inadecuado con datos desbalanceados. Se definió un umbral económico basado en el costo diferencial de los errores: perder un cliente potencial (**\$120**) cuesta 12× más que una llamada infructuosa (**\$10**). El umbral óptimo resultante fue **0.41**.

## CURVA DE GANANCIA

Ordenando los clientes de mayor a menor score, el modelo concentra los suscriptores en el top del ranking:

| Top del ranking | Suscriptores capturado |
|-----------------|------------------------|
| 10% contactado  | 47.4%                  |
| 20% contactado  | 67.2%                  |
| 30% contactado  | 75.1%                  |
| Aleatorio (20%) | ~20.0%                 |

## RESULTADOS EN TEST

El modelo se evaluó **una sola vez** sobre datos que no participaron en ninguna decisión de diseño. Intervalo de confianza del 95% calculado por bootstrap (n=1,000):

| Métrica        | Test  | IC 95%         |
|----------------|-------|----------------|
| ROC-AUC        | 0.816 | [0.799, 0.832] |
| Avg. Precision | 0.495 | [0.462, 0.531] |
| F1-score (yes) | 0.447 | —              |
| Brier Score    | 0.149 | —              |

## IMPACTO OPERATIVO

| Estrategia               | Llamadas     | Capturas     |
|--------------------------|--------------|--------------|
| Contacto total           | 100%         | 100%         |
| Umbral 0.5               | 68%          | 69.8%        |
| <b>Modelo (thr 0.41)</b> | <b>24.3%</b> | <b>70.5%</b> |

## RECOMENDACIÓN

- Desplegar el modelo como sistema de **priorización de listas de contacto**, operando al umbral 0.41.
- Intensificar campañas en **ventanas económicas favorables** (empleo alto, euribor bajo).
- Reentrenar cuando el contexto macroeconómico se aleje del período 2008-2010.
- Calibrar probabilidades antes de despliegue en producción.