
Bank Marketing Lead Scoring

Predicción de Suscripción a Depósito a Término mediante Clasificación Binaria

Alejandro Osorno · Danna Mendoza

Aprendizaje de Máquina Aplicado — EAFIT · Mayo 2026

Dataset: UCI Bank Marketing · bank-additional-full.csv · 41,188 registros

Resumen

Se presenta un sistema de lead scoring para campañas de telemarketing bancario basado en clasificación binaria. El objetivo es predecir si un cliente suscribirá un depósito a término antes de realizar la llamada, permitiendo priorizar el esfuerzo comercial sobre los clientes más propensos a convertir. Sobre el dataset UCI Bank Marketing (41,188 registros, 11.3% de positivos), se compararon seis configuraciones de modelos bajo un protocolo estricto de validación cruzada estratificada de cinco folds. El modelo final, LightGBM optimizado con Optuna, alcanza un ROC-AUC de 0.816 y un Average Precision de 0.495 en el conjunto de prueba, retenido intacto hasta la evaluación final. Operando con un umbral de decisión calibrado por costo de negocio (ratio FN:FP de 12:1), el modelo captura el 70.5% de los suscriptores reales contactando solo al 24.3% de la base, con un ahorro del 36.6% frente a la estrategia de contacto indiscriminado.

Palabras clave: lead scoring · clasificación binaria · desbalance de clases · LightGBM · telemarketing bancario · Average Precision

1. Formulación del problema y contexto de negocio

Un banco portugués realiza campañas de telemarketing para ofrecer depósitos a término a sus clientes. El proceso actual consiste en llamar a una fracción amplia de la base de clientes, lo cual genera un costo operativo considerable considerando que, históricamente, solo el **11.3% de los clientes contactados acepta la oferta**. El 88.7% restante representa llamadas infructuosas que consumen tiempo de los agentes y degradan la experiencia del cliente.

La pregunta central del proyecto es: *¿es posible predecir, a partir de características del cliente y del contexto macroeconómico disponibles antes de realizar la llamada, si un cliente aceptará la oferta de depósito a término?* Una respuesta afirmativa permitiría construir un sistema de *scoring* que priorice las llamadas, concentrando el esfuerzo en los clientes con mayor probabilidad de conversión.

¿Por qué este problema requiere Machine Learning? La relación entre el perfil del cliente y la decisión de suscribir no es lineal ni interpretable mediante reglas simples. El EDA confirma que variables macroeconómicas como la tasa Euribor a 3 meses y el nivel de empleo interactúan con el historial de contacto del cliente de forma no trivial. Un umbral fijo o una segmentación manual no capturan estas interacciones.

1.1. Definición formal de la tarea

Clasificación binaria supervisada sobre la variable objetivo y (sí/no suscribe), con salida interpretada como *score* de propensión para ordenar la lista de contacto.

2. Dataset y calidad de datos

Se utilizó el dataset Bank Marketing de UCI, versión extendida (bank-additional-full.csv). El archivo contiene 41,188 registros y 21 variables, incluyendo información demográfica del cliente, datos de la campaña actual y contexto macroeconómico del período de contacto.

Grupo	Variables	Tipo
Perfil del cliente	age, job, marital, education, default, housing, loan	Mixto
Campaña actual	contact, month, day_of_week, duration*, campaign, pdays, previous	Mixto
Resultado anterior	poutcome	Categorico
Macroeconómico	emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m, nr.employed	Numérico
Objetivo (target)	y (yes / no)	Binario

* duration excluida por target leakage (ver §3.2).

2.1. Desbalance de clases

El 88.73% de los registros pertenece a la clase negativa (no suscribe) y solo el 11.27% a la positiva. Este desbalance hace que la exactitud (*accuracy*) sea una métrica engañosa: un clasificador trivial que prediga siempre "no" obtiene 88.7% de exactitud sin aprender nada. Esto motivó la elección del **Average Precision (PR-AUC)** como métrica principal, que se focaliza en el desempeño sobre la clase minoritaria.

2.2. Tratamiento de faltantes y categorías especiales

- La variable pdays usa el valor 999 para indicar que el cliente nunca fue contactado previamente. Se transformó en una variable binaria nunca_contactado y el 999 se reemplazó por NaN para su tratamiento mediante imputación.
- Las categorías "unknown" se conservaron como valor propio en lugar de imputarse, dado que la ausencia de información puede ser un predictor en sí mismo.
- No se encontraron valores nulos en el sentido estricto; todos los faltantes estaban codificados como "unknown".

3. Metodología

3.1. Particionamiento y estratificación

El dataset se dividió en tres particiones mediante *train_test_split* con estratificación sobre la variable objetivo, semilla fija SEED=42 y los siguientes proporciones:

Partición	Filas	Proporción	Positivos	Uso
Train	26,360	64%	11.27%	Ajuste de parámetros y selección por CV
Validation	6,590	16%	11.26%	Reporte intermedio (Entrega 2)
Test	8,238	20%	11.26%	Evaluación final, una sola vez (Entrega 3)

El mismo split se mantuvo idéntico en las tres entregas, verificable mediante *hashes* de índices impresos al inicio de cada notebook. El conjunto de test permaneció intacto y no fue consultado en ninguna decisión de diseño.

3.2. Prevención de data leakage

Se identificaron y controlaron tres fuentes de fuga de información:

- **Leakage conceptual:** la variable *duration* (duración de la llamada en segundos) se excluye desde el inicio porque no es conocida antes de realizar la llamada. Su inclusión generaría métricas artificialmente infladas.
- **Leakage de preprocesamiento:** todo el preprocesador (imputación, estandarización, codificación) se encapsuló en un Pipeline que solo se ajusta con el fold de train en cada iteración de la validación cruzada.
- **Leakage de threshold:** el umbral de decisión se seleccionó mediante *out-of-fold predictions* sobre train usando *cross_val_predict*, sin acceder a validation ni test.

3.3. Pipeline de preprocesamiento

Tipo de variable	Transformación
Numéricas	Imputación por mediana + StandardScaler
Nominales	Imputación por moda + OneHotEncoder (handle_unknown='ignore')
Ordinal (education)	Orden educativo explícito + OrdinalEncoder
pdays=999	→ variable binaria nunca_contactado + reemplazo por NaN

3.4. Métricas de evaluación

Average Precision (AP / PR-AUC) es la métrica principal. Equivale al área bajo la curva Precision-Recall y resume el desempeño del modelo en todos los umbrales posibles, ponderando especialmente el desempeño sobre la clase positiva. Es más informativa que el ROC-AUC cuando existe desbalance pronunciado, dado que el ROC puede ser optimista al ignorar la relativa escasez de la clase positiva.

ROC-AUC se reporta como métrica secundaria para comparabilidad con la literatura. **F1-score** se reporta al umbral óptimo. Las comparaciones entre modelos siempre se hacen con **media ± desviación estándar** sobre los cinco folds para distinguir señal de ruido.

4. Baseline y dificultad del problema

Se establecieron dos baselines sobre el conjunto de validación (Entrega 1). El Dummy (clase mayoritaria) fija el piso absoluto; la Regresión Logística sin tuning establece la referencia de un modelo lineal simple.

Modelo	ROC-AUC (val)	AP (val)	F1 yes (val)
Dummy (clase mayoritaria)	0.500	0.113	0.000
Regresión Logística (C=1, sin tuning)	0.795	0.437	0.335

La Regresión Logística ya supera el Dummy en más de 0.29 puntos de ROC-AUC, confirmando que **existe señal predictiva real en el dataset**. Sin embargo, un F1 de 0.335 al umbral por defecto (0.5)

indica que el desbalance dificulta la detección de positivos con un clasificador lineal sin ajuste de umbral. Esta referencia es la vara contra la cual se miden todas las familias posteriores.

5. Comparación de familias de modelos

Se compararon seis configuraciones cubriendo cuatro familias de aprendizaje distintas. Todas se evaluaron bajo el mismo protocolo: validación cruzada estratificada de cinco folds sobre el conjunto de train, con el preprocesador ajustado dentro de cada fold. Los hiperparámetros se seleccionaron con GridSearchCV (Entrega 2) y Optuna—TPE (Entrega 3), ambos optimizando Average Precision.

Modelo	ROC-AUC (CV)	AP (CV)	Nota
Regresión Logística	0.787 ± 0.012	0.445 ± 0.022	Baseline
Árbol de Decisión (GS)	0.774 ± 0.009	0.432 ± 0.023	Overfitting controlado
Random Forest (GS)	0.788 ± 0.014	0.458 ± 0.020	Balanced weights
SVM RBF (subsample 8k)	0.763 ± 0.015	0.351 ± 0.028	Lento, cal. comprimida*
Random Forest (Optuna)	0.794 ± 0.014	0.459 ± 0.020	Mejor CV en E2
LightGBM (Optuna)	0.794 ± 0.024	0.463 ± 0.024	MODELO FINAL

* El SVM se entrenó sobre una submuestra estratificada de 8,000 filas por costo computacional.

Hallazgo principal de la comparación: las diferencias entre los modelos con mejor desempeño (LightGBM, RF Optuna, RF GS y Regresión Logística) son menores a una desviación estándar combinada. El problema presenta un *techo de señal* que los modelos de distintas familias alcanzan de forma convergente. **LightGBM** fue elegido como modelo final porque lidera de forma consistente en AP, ofrece interpretabilidad mediante importancia de variables, sus probabilidades están mejor calibradas que el SVM, y tiene menor costo computacional que el RF equivalente.

5.1. Ajuste de umbral con función de costo

Con datos desbalanceados, el umbral por defecto de 0.5 es inadecuado. Se definió una función de costo de negocio con los siguientes supuestos:

- **Costo de Falso Negativo (FN) = 120 unidades:** cliente que sí habría suscrito pero no fue contactado → venta perdida.
- **Costo de Falso Positivo (FP) = 10 unidades:** llamada a alguien que no suscribe → tiempo del agente.
- **Ratio FN:FP = 12:1,** estimación razonable para telemarketing bancario.

El umbral que minimiza el costo total esperado se seleccionó sobre las *out-of-fold predictions* de train mediante `cross_val_predict`. El threshold óptimo resultante fue **0.41**, con un recall de 0.674 y una tasa de alertas del 24.8%.

6. Evaluación final en el conjunto de prueba

El conjunto de test fue utilizado **una única vez**, después de cerrar todas las decisiones de diseño. El modelo final se reentrenó sobre train+validation antes de la evaluación, aprovechando el máximo de datos disponibles que no son test.

Métrica	Valor	IC 95% (bootstrap, n=1,000)
ROC-AUC	0.8157	[0.7989, 0.8319]
Average Precision	0.4947	[0.4618, 0.5308]
F1-score (yes)	0.4469	— (depende del umbral)
Brier Score	0.1486	—

6.1. Matriz de confusión y métricas operativas

Tipo	n (test)	% de su clase	Interpretación
Verdaderos Positivos	654	70.5%	Suscriptores correctamente identificados
Falsos Positivos	1,345	18.4% del total	Llamadas sin conversión
Falsos Negativos	274	29.5%	Oportunidades perdidas
Verdaderos Negativos	5,965	81.6% del total	No contactados, correcto

6.2. Impacto de negocio

Escenario	Clientes llamados	Suscriptores capturados	Costo total
Llamar a todos	8,238 (100%)	928 (100%)	73,100
Threshold 0.5	~5,600 (68%)	~648 (69.8%)	46,870
Threshold negocio 0.41	1,999 (24.3%)	654 (70.5%)	46,330

La curva de ganancia acumulada muestra que, ordenando a los clientes por score descendente, llamando al **top 10%** se captura el **47.4%** de los suscriptores; al **20%** se captura el **67.2%**; y al **30%** el **75.1%**. El modelo concentra efectivamente los clientes propensos en la parte alta del ranking, que es el objetivo de un sistema de *lead scoring*.

7. Interpretación del modelo

La importancia de variables se calculó mediante *permutation importance* sobre el conjunto de test, midiendo la caída en AP al permutar aleatoriamente cada variable. Este método es agnóstico al tipo de modelo y mide el impacto causal de cada variable sobre el desempeño real.

Variable	Importancia	Grupo
nr.employed	0.1339	Macroeconómico
nunca_contactado	0.0359	Historial de contacto
euribor3m	0.0285	Macroeconómico
contact	0.0218	Campaña actual
cons.conf.idx	0.0119	Macroeconómico
poutcome	0.0108	Historial de contacto

campaign	0.0080	Campaña actual
----------	--------	----------------

Hallazgo central de la interpretación: la variable más influyente por amplio margen es nr.employed (número de empleados trimestral, indicador de ciclo económico), con una importancia de 0.134, más de tres veces la del segundo predictor. Esto revela que el modelo predice más *cuándo* es buen momento para la campaña que a *quién* llamar. Las variables macroeconómicas (nr.employed, euribor3m, cons.conf.idx) acumulan la mayor parte de la señal predictiva, por encima del perfil individual del cliente.

Implicación accionable: el banco debería priorizar la *ventana temporal* de la campaña (condiciones de empleo y tasas favorables) como primer criterio de lanzamiento, y usar el scoring individual para ordenar a los clientes dentro de esa ventana.

7.1. Calibración del score

El diagrama de calibración muestra que LightGBM tiende a subestimar las probabilidades en la zona media (0.2-0.6), lo cual es típico de modelos de árboles sin calibración explícita. El Brier Score de 0.149 indica calibración razonablemente buena para uso operativo. Para un despliegue en producción se recomienda calibración isotónica o de Platt para alinear mejor las probabilidades predichas con las frecuencias observadas.

8. Generalización y confiabilidad de los resultados

El AP en test (0.4947) cae dentro del rango esperado por la validación cruzada (0.4633 ± 0.0236), específicamente a menos de dos desviaciones estándar de la media de CV. Esto confirma que el protocolo de validación fue honesto y que el desempeño reportado es una estimación confiable de cómo se comportaría el modelo en producción.

El intervalo de confianza del 95% para el AP, estimado mediante bootstrap con 1,000 remuestreos del test, es **[0.462, 0.531]**. Este rango excluye al baseline de Regresión Logística (AP=0.437 en test), sugiriendo que la mejora de LightGBM sobre el baseline sí es estadísticamente distinguible en la evaluación final, aunque en CV ambos modelos estaban dentro de una desviación estándar.

9. Análisis de errores

El análisis segmentado de los falsos negativos (positivos reales que el modelo no detecta) revela dos patrones consistentes:

- **Por resultado de campaña previa (poutcome):** los clientes sin historial de contacto (nonexistent) tienen la tasa de FN más alta (~40%), mientras que los clientes con campaña previa exitosa (success) prácticamente no generan falsos negativos. Cuando no hay historial previo, el modelo tiene menos señal y es más conservador.
- **Por mes de la campaña:** julio y mayo muestran las tasas de FN más altas (~60% y ~52%), coincidiendo con los meses de mayor volumen de contactos, donde el desbalance local es más pronunciado.

Estos patrones son accionables: para clientes sin historial previo y en meses de alto volumen, el banco podría complementar el modelo con criterios comerciales adicionales o reducir el umbral localmente.

10. Limitaciones

- **Ventana temporal acotada:** el dataset cubre campañas de 2008-2010, durante una crisis financiera europea. Las variables macroeconómicas que dominan el modelo pueden no generalizar a contextos económicos actuales sin reentrenamiento.
- **Una sola institución:** los datos provienen de un único banco portugués. La generalización a otros mercados, productos o países requiere revalidación.
- **Costos asumidos:** el ratio FN:FP de 12:1 es una estimación razonable. El umbral óptimo cambia con los costos reales: el análisis de sensibilidad muestra que con ratio 5:1 el umbral sube a ~0.55 y con 20:1 baja a ~0.06.
- **SVM no comparable directamente:** el SVM se entrenó sobre una submuestra de 8,000 filas por costo computacional, por lo que sus métricas de CV no son directamente comparables con las de los demás modelos.
- **Fairness no analizado:** variables como job, marital y education podrían introducir sesgo demográfico. Un análisis de equidad es necesario antes de un despliegue real.
- **Calibración subóptima:** LightGBM tiende a subestimar probabilidades en la zona media; un sistema de scoring en producción debería incluir calibración explícita.

11. Conclusiones y próximos pasos

El proyecto demuestra que es posible predecir con confianza razonable si un cliente suscribirá un depósito a término antes de realizar la llamada. LightGBM, calibrado con un umbral de decisión derivado de la economía del negocio, permite contactar solo al **24.3% de los clientes** y capturar el **70.5% de los suscriptores reales**, con un ahorro del 36.6% frente a la estrategia de contacto indiscriminado.

El hallazgo técnico más importante es la dominancia de las variables macroeconómicas sobre el perfil individual del cliente. Esto sugiere que el valor del modelo reside tanto en identificar el momento óptimo de la campaña como en priorizar a los clientes dentro de ese momento.

El hallazgo metodológico más importante es que el problema tiene un techo de señal que los modelos de distintas familias alcanzan de forma convergente: la ventaja de LightGBM sobre la Regresión Logística es modesta en CV (0.019 puntos de AP), aunque se vuelve estadísticamente distinguible en el test set.

11.1. Próximos pasos recomendados

- **Calibración de probabilidades** (calibración isotónica o de Platt) para alinear el score con frecuencias reales y hacer el umbral más interpretable.
- **Feature engineering macroeconómico:** construir índices compuestos o rezagos de las variables económicas para capturar la dinámica temporal de la campaña.
- **Análisis de fairness** sobre variables demográficas sensibles antes de cualquier despliegue real.
- **Monitoreo de deriva** (*data drift*): las variables macroeconómicas son intrínsecamente no estacionarias; el modelo debe reentrenarse cuando el contexto económico se aleje del período de entrenamiento.
- **Pipeline de scoring en tiempo real:** integrar las variables económicas actualizadas y servir el score como API para el sistema CRM del banco.

Nota de reproducibilidad

Semilla: SEED=42. Split verificable por hashes: train=34959e7af23a, val=f3a6afbe3a7d, test=fb1445d245c0. Pipeline guardado en report/modelo_final_e3.joblib. Dependencias en requirements.txt. Repositorio: <https://github.com/dcmendoza/ml-lead-scoring-bank-marketing>